

面向 WebShop 的微调与策略控制结合的 LLM Agent

Group 34

Final Project

廖燚齐 25210980075

Abstract

本文研究 WebShop 交互式购物环境中的大语言模型智能体。该任务要求模型理解自然语言购物目标，生成检索查询，比较商品页面，并在有限步数内完成购买决策。我们以 Qwen2.5-7B-Instruct 的 ReAct 智能体为基线，依次评估关键词检索提示、监督微调 (SFT)、失败模式诊断和轻量级 anti-loop 策略控制器。实验显示，原始 ReAct 在 50 条 full synthetic goals 上的 strong success rate 为 10%，关键词提示将其提升到 20%。然而，直接使用统一轨迹训练得到的 SFT 模型反而下降到 2%，主要原因是模型容易重复搜索而不进入点击或购买阶段。加入保守的 anti-loop 控制器后，统一 SFT 模型达到 48% strong success rate，是本项目中表现最好的配置。结果表明，SFT 可以改善部分语言理解与检索行为，但 WebShop 这类交互式任务仍然需要显式的阶段转换控制。

1 引言

Web shopping 是一个具有现实意义的语言智能体任务：模型不仅要理解用户约束，还要将目标转化为可检索的关键词，浏览商品结果，选择具体商品和选项，并判断何时购买。与单轮问答不同，WebShop 要求智能体在多个动作之间保持状态一致性，因此它同时考验语言理解、检索、页面阅读和交互策略。

本项目最初采用三阶段思路：首先建立 ReAct baseline，然后通过 SFT 学习更好的行动轨迹，最后引入奖励感知的策略控制。实际实验中我们发现，朴素 SFT 并没有直接带来收益。进一步诊断表明，SFT 模型虽然能生成更像训练数据的查询，但经常陷入 repeated-search/no-buy loop，即反复搜索而不点击商品，或已经进入商品页面却不购买。因此，我们将实验重点转向失败模式分析，并实现了一个确定性的 anti-loop controller 作为轻量策略层。

本文贡献可以概括为三点：第一，在 full WebShop 商品索引上复现并比较 ReAct、关键词提示和 SFT 智能体；第二，通过失败诊断解释 SFT 失效的主要原因；第三，证明简单的阶段转换控制器可以显著改善 SFT 智能体的交

互成功率。

2 相关工作

WebShop 是一个面向真实电商交互的 benchmark，包含大规模商品库、自然语言 shopping goals 和基于 reward 的评价方式 [1]。ReAct 框架通过交替生成 reasoning 和 action，使语言模型能够在交互环境中逐步决策 [2]。在偏好学习方面，DPO 将 preference optimization 转化为直接优化 chosen/rejected response 的目标函数 [3]，理论上适合修正 WebShop 中的局部动作偏好，例如 repeated search 与 click 之间的选择。

原始 WebShop 论文报告的自动 agent 成功率仍明显低于人类专家：rule-based heuristic 约为 9.6%，其最优模型约为 29%，而 human expert 约为 59% [1]。这说明购物环境中的主要困难并不只是语言理解，还包括检索、探索和购买时机控制。近年的 web agent 研究也常发现，LLM 具备较强的文本理解能力，但在长程交互中仍容易出现循环、过早提交或无法完成最终动作等问题。

与这些工作相比，本项目不是追求 benchmark-level SOTA，而是在课程项目范围内分析一个小型 LLM agent pipeline 的真实失败模式。我们的主要发现是：对于 WebShop，模型生成能力和交互控制能力不能简单等同。SFT 学到的局部语言模式如果没有合适的状态转换约束，可能会损害整体任务成功率。因此，本文的重点不是简单堆叠更大模型，而是研究如何通过诊断和轻量控制让已有模型更可靠地完成交互流程。

3 任务与数据

我们使用 WebShop full mode，共包含约 1.18M 个商品，并构建完整 Lucene 检索索引。每个 episode 中，智能体接收一个购物目标，并通过文本动作与环境交互。主要动作包括 search[keywords]、click[ASIN]、click[option] 和 click[Buy Now]。

主实验使用 synthetic goals 0-49，共 50 条任务，每个 episode 最多 7 步。我们报告两个指

标：平均 reward 和 strong success rate。Strong success 定义为 episode reward 大于 0.5。需要强调的是，该设置用于课程项目中的受控比较，并不是原始 WebShop benchmark 的完整 500-goal 测试。

3.1 数据预处理与索引

为了避免只在小规模 toy environment 上得到不稳定结论，我们将实验环境切换到 full product setting。原始商品文件被重新整理为 WebShop 检索所需的 JSONL 文档格式，并使用 Pyserini 构建 Lucene index。最终索引对应 1,181,430 个商品文档。与 sample setting 相比，full setting 的检索噪声更高，search query 的长度、关键词选择和商品点击时机都会直接影响后续 reward。因此，本项目没有把检索模块视为固定黑盒，而是把 query formulation 作为 agent 行为的一部分进行分析。

轨迹数据清洗主要关注动作格式一致性和明显损坏样本。对于 SFT 数据，我们保留能够映射到 WebShop action space 的 search/click/buy 动作，过滤格式不完整或无法解析的轨迹。对于后续 DPO 准备，我们没有直接使用自动生成的偏好对作为最终训练数据，因为初步检查发现部分 chosen/rejected 元数据没有严格对齐同一 observation。这个问题会使 preference learning 学到错误信号，因此本文只将其作为未来工作，而不报告 DPO 性能。

4 方法

4.1 ReAct Baseline

原始 baseline 使用 Qwen2.5-7B-Instruct，根据当前 observation 生成一个简短 thought 和一个 WebShop action。该方法的优点是结构简单、可解释性较好；主要缺点是模型常生成过长、过自然语言化的搜索查询，导致检索结果质量不稳定。

4.2 关键词检索提示

早期实验显示，search query 的质量对 WebShop 成败影响很大。原始 ReAct 往往把完整购物目标直接塞进 search[]，包含大量修饰语和约束条件。我们加入 keyword-only prompt，要求模型在搜索阶段使用 3–6 个关键词，优先保留商品类型、品牌、尺寸、颜色、功能等高信息量词。该修改不改变模型参数，只改变查询生成行为。

4.3 监督微调

我们使用 LoRA adapter 对模型进行 SFT，训练数据来自清洗后的 WebShop-style trajectories

和 query examples。SFT 的目标是让模型学习更稳定的搜索和行动格式。实验中我们分别尝试专家轨迹与统一清洗轨迹，其中 unified SFT 是后续诊断和 controller ablation 的主要对象。

需要强调的是，SFT 在本项目中不是最终答案，而是一个需要被诊断的中间步骤。统一 SFT adapter 使用约 14,544 条清洗轨迹训练。训练后模型确实表现出更强的检索倾向，生成的查询更像轨迹数据中的商品关键词组合；但这种模仿学习并没有自动转化为更高 reward。这个现象促使我们将模型能力拆分为两个层面：一是生成较好查询和合法动作的语言能力，二是知道何时从搜索转向点击、从浏览转向购买的策略能力。

4.4 失败诊断

SFT 后的 aggregate performance 明显下降，因此我们没有继续盲目扩大训练，而是对 episode 进行失败类型统计。主要失败包括 zero-result search、repeated search、max-step no-buy、wrong product 和 premature buy。其中最突出的现象是 repeated-search/no-buy loop：模型在应该点击商品时继续搜索，或在商品页附近没有及时购买。

4.5 Anti-loop Controller

基于诊断结果，我们实现了一个确定性的 anti-loop controller。它不是学习得到的 Bandit，而是一个策略控制原型，核心规则包括：

- 如果模型重复生成相同或高度相似的搜索动作，则强制点击当前可见商品；
- 如果连续搜索次数过多，则从搜索阶段转入点击阶段；
- 如果已在商品页面且接近最大步数，则保守触发购买动作。

该控制器的目标不是替代语言模型，而是修正 SFT 在交互阶段转换上的系统性错误。

4.6 DPO 准备

DPO 是本项目后续自然延伸，尤其适合构造 action-level preference pairs，例如“重复搜索”作为 rejected action，“点击候选商品”作为 chosen action。然而，当前最终正向结果不依赖 DPO。我们只保留了 DPO 数据构造计划和训练脚本，没有将 DPO 结果作为已完成贡献报告。

5 实验设置

所有主要评估都在相同的 full WebShop environment 上进行，并使用相同的 50 条 synthetic

系统	Strong SR	Avg. Reward
Raw ReAct	10%	0.077
Keyword baseline	20%	0.209
Unified SFT	2%	0.012
SFT + controller	48%	0.419

Table 1: 50 条 full synthetic goals 上的主实验结果。

Controller 变体	Strong SR	Avg. Reward
No controller	2%	0.012
Repeat-to-click only	22%	0.182
No forced buy	22%	0.192
Conservative forced buy	48%	0.419
Aggressive controller	48%	0.446

Table 2: Unified SFT 上的 controller ablation。

goals。为了降低环境加载和模型加载带来的时间开销，我们将多个配置放入统一 evaluator 中顺序运行。每个 episode 的最大步数设为 7，这一设置使 agent 必须在少数步骤内完成 search、click、option selection 和 buy 的转换，也使 repeated search 问题更容易暴露。

我们比较四类系统。Raw ReAct 是不加额外约束的基础提示；keyword baseline 只改变 search action 的提示方式；unified SFT 使用清洗轨迹训练得到的 LoRA adapter；unified SFT + controller 在模型输出后加入确定性 anti-loop 修正。这样的设置可以区分三类因素：提示工程是否改善检索入口，SFT 是否改善整体策略，以及 controller 是否能修正多步交互中的阶段转换错误。

6 实验结果

表 1 展示了主实验结果。Raw ReAct 的 strong success rate 为 10%，说明原始模型在 WebShop 中具备一定零样本交互能力，但稳定性较弱。关键词提示将 strong success rate 提升到 20%，验证了 query reformulation 对检索任务的重要性。Unified SFT 单独使用时只有 2%，说明模仿轨迹格式并不等于学会完整交互策略。加入 conservative controller 后，strong success rate 提升到 48%，平均 reward 达到 0.419。

表 2 进一步说明 controller 的有效成分。仅加入 repeat-to-click 规则即可从 2% 提升到 22%，说明搜索到点击的阶段转换是关键瓶颈。若不允許 forced buy，成功率仍停留在 22%。加入保守购买规则后，成功率达到 48%。Aggressive controller 的平均 reward 略高，但 strong success rate 与 conservative controller 相同；考虑到误买风险，本文将 conservative controller 作为主结果。

系统或参考	评估来源	Success
Rule-based heuristic	原始论文	9.6%
Best reported model	原始论文	29%
Human expert	原始论文	59%
Ours: Raw ReAct	本文 50-goal	10%
Ours: Keyword baseline	本文 50-goal	20%
Ours: SFT + controller	本文 50-goal	48%

Table 3: 与已有 WebShop 结果的定位性比较。不同来源的评估协议不完全一致，因此该表用于说明结果量级，而非声明 benchmark SOTA。

6.1 与已有工作的对比

表 3 给出了一个定位性比较。这里的数字不能被解释为严格 leaderboard 对比，因为评估 split、模型规模、最大步数和 success 定义并不完全相同；但它有助于说明本项目结果的量级。原始 WebShop 论文中的 rule-based heuristic 约为 9.6%，最优自动模型约为 29%，human expert 约为 59%。我们的 raw ReAct baseline 为 10%，与 rule-based heuristic 同一量级；keyword prompt 后达到 20%，说明仅改善查询形式已经能接近早期自动 agent 的一部分能力；SFT + conservative controller 在 50 条 full synthetic goals 上达到 48%，明显高于我们自己的 raw/keyword/SFT baselines，也接近人类专家和早期自动 agent 之间的中间区域。

这个对比也揭示了本文方法的主要优点。Raw ReAct 依赖模型自身的隐式策略，容易生成冗长查询；keyword prompt 只修正检索入口，无法解决购买时机；SFT 学到了更强的搜索模式，却放大了搜索循环。我们的 controller 并不尝试替代语言模型，而是在模型最容易失控的阶段施加最小干预。因此，提升来自“语言生成能力”和“交互阶段控制”的互补，而不是单纯来自更多训练数据或更复杂提示。

7 失败模式分析

从 episode 级别日志看，Raw ReAct 的主要问题是搜索查询过长或过于接近自然语言描述。例如模型会把价格、颜色、用途和完整约束全部写进 search[]，导致检索结果为空或高度偏离。Keyword prompt 的提升说明，WebShop 中的第一步检索不是简单文本生成任务，而是一个需要压缩目标约束的信息抽取任务。

Unified SFT 的失败更加反直觉。它并不是完全不会搜索，而是经常生成看似合理的 search action 后继续搜索，缺少从结果列表进入商品页面的转换。这个现象说明，SFT 可以学习局部动作分布，却未必能学到 reward-oriented transition policy。换言之，训练轨迹中出现频率高的 search pattern 可能被模型过度模仿，而“何时停止搜索”这一决策没有被充分学习。

Controller 的作用正是补上这一缺口。Repeat-to-click 规则直接针对重复搜索循环，forced-buy 规则针对接近步数上限时仍不购买的问题。Ablation 结果显示，如果只解决 search 到 click 的转换，成功率只能提升到 22%；若再加入保守购买规则，成功率达到 48%。这表明 WebShop agent 的关键瓶颈至少包含两个阶段转换：search-to-click 和 inspect-to-buy。

进一步看，unified SFT 的失败并不意味着 SFT 完全无用。诊断结果显示，它的 zero-result search rate 低于 baseline，说明模型确实学到了某些更有效的搜索表达；真正的问题是搜索之后的决策被削弱了。换句话说，SFT 改善了 retrieval-facing 行为，却破坏或没有学习到 decision-facing 行为。本文方法的核心就是保留 SFT 在搜索上的收益，同时用 controller 修正后续决策缺口。

8 讨论

实验结果表明，WebShop agent 的难点不只是生成正确文本动作，还包括在合适时间从一个阶段转入下一个阶段。关键词提示之所以有效，是因为它直接改善了检索入口；SFT 之所以失败，是因为它学习到了局部动作形式，却没有稳定学习“搜索-点击-选择-购买”的全局流程。

这一现象也解释了为什么 controller 可以带来较大提升。Controller 不需要理解所有商品细节，它只负责在明显循环或接近步数上限时强制推进状态。因此，语言模型和策略控制器形成了互补：模型负责理解目标和生成候选动作，controller 负责限制无效循环并保持任务进度。

从实验设计角度看，本文最重要的经验是：当 SFT 结果异常下降时，不能只通过增加训练轮数或扩大数据继续尝试，而应先检查真实 episode 的失败模式。否则，模型可能在 aggregate metric 上持续退化，而研究者无法判断问题来自检索、动作格式、购买时机还是奖励定义。

这种诊断驱动的开发方式也是本项目相对简单 baseline 的优势。若只观察最终 reward，SFT 的 2% strong success 似乎说明微调方向完全错误；但 episode 分析表明，模型已经学到了一部分可用能力，只是缺少阶段转换约束。因此，最终方案不是放弃 SFT，而是将 SFT 和 controller 分工：SFT 负责产生更合理的语言动作分布，controller 负责限制循环并确保任务推进。对于资源有限的课程项目，这种分层改进比重新训练大型策略模型更可控，也更容易解释。

9 局限与未来工作

本项目仍有明显局限。首先，主实验只在 50 条 synthetic goals 上评估，结论不能直接等同于完整 WebShop benchmark。其次，controller 是确定性规则，不是学习得到的 Bandit，因此只能视为策略控制原型。第三，DPO 尚未形成可靠的训练和评估闭环；尤其是 preference pair 必须严格对齐同一 observation 下的 chosen/rejected action，否则会引入噪声甚至错误学习信号。

未来工作可以沿三条方向推进：第一，扩大评估到更多 synthetic goals 或 human goals；第二，构造 observation-aligned DPO 数据，专门修正 repeated search、no-buy 和 premature buy；第三，将当前规则 controller 替换为 contextual Bandit 或轻量 learned policy，使策略层能够根据 observation、检索结果数量和历史动作自适应决策。

10 结论

本文围绕 WebShop 构建并分析了一个 Qwen2.5-7B-Instruct 智能体实验链路。实验显示，原始 ReAct 可以完成少量任务，关键词提示能改善检索表现，但朴素 SFT 会因 repeated-search/no-buy loop 显著退化。通过失败诊断引入 conservative anti-loop controller 后，统一 SFT 模型在 50 条 full synthetic goals 上达到 48% strong success rate。该结果说明，在交互式购物任务中，微调语言模型需要与显式策略控制结合，才能更稳定地完成多步决策。

References

- [1] Shunyu Yao, Howard Chen, John Yang, and Karthik Narasimhan. 2022. WebShop: Towards Scalable Real-World Web Interaction with Grounded Language Agents. In *Advances in Neural Information Processing Systems*.
- [2] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. 2023. ReAct: Synergizing Reasoning and Acting in Language Models. In *International Conference on Learning Representations*.
- [3] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. 2023. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. In *Advances in Neural Information Processing Systems*.