

WebShop LLM Agent

从零样本 ReAct 基线到策略优化的购物智能体

Qwen2.5-7B

基座模型

A100 40G

算力底座

LoRA/ReAct

技术框架

NLP Final Project · Group 34 · 2026-05-28

深入解读：WebShop 原论文 (NeurIPS 2022)

Princeton NLP · Yao, Chen, Yang & Narasimhan · 首个大规模真实电商 Agent 基准

要素	详情
任务	Agent 理解购物指令，在模拟网站执行 搜索→翻页→选品→选属性→购买，程序化自动评估
环境	4类网页 (Search/Results/Item/Detail) · 6种动作 (search/click/buy/翻页/返回/详查)
奖励	$r = r_{\text{type}} \times (\text{attrs_matched} + \text{options_matched} + 1[\text{price} \leq \text{budget}]) / (\text{attrs_required} + \text{options_required} + 1) \cdot \text{Score} = 100 \times \text{avg_r}$
数据	1.18M 商品 · 12,087 条指令 · 1,571 IL轨迹 · 500 test split

原论文架构：BART+BERT 双模型流水线



IL 阶段：
BART/BERT 各 10 epochs · 1,571 条人类轨迹 · CE loss

RL 阶段：
在线交互 · PG + TD + IL正则化 + entropy bonus

原论文最佳结果 (500 test goals)



论文揭示的未解决挑战

搜索词生成与改写 · 复合指令理解 · 策略性探索 (何时翻页/比较/购买) · 非结构化网页文本理解 · 仿真→真实迁移 · 这三个方向至今仍是开放问题

我们从原论文继承了什么

- 完全相同的任务定义、奖励函数和评估环境
- IL 轨迹 + goal-query 对作为核心训练数据
- 500 条标准 test split 评估协议
- 改进点：单一 7B LLM 替换双模型 + 递进式实验 + Bandit 策略层

2022→2024 研究演进 + 我们的实验设计

从 BART/BERT 双模型到 LLM+ReAct 统一框架，对标 A3T 路线

2024 年四篇顶会论文的演进

A3T (COLM 2024) Mistral-7B · r=1.0 SFT · binarized PG · 4轮自训练 → Score 74	IPR (EMNLP 2024) Step-level DPO · Monte Carlo · 迭代 → Score 70
ETO (2024) 失败轨迹对比训练 · GPT-4 CoT回填	DMPO (EMNLP 2024) 多轮DPO · 长度归一化 → Score 70

共同趋势：单一7B LLM + ReAct推理链 + 迭代自训练。论文已证明这个范式远超原BERT/BART。

维度	原论文 (2022)	A3T (2024)	本小组
模型	BART+BERT (0.5B)	Mistral-7B	Qwen2.5-7B
架构	双模型/无推理链	ReAct/统一	ReAct/统一思维链
训练	IL 10ep + RL PPO	QLoRA + PG	LoRA + PG + DPO
数据筛选	全量轨迹	仅 r=1.0	探索 r>0.5→r=1.0
Score	62.4	73.9	目标 75+ (Full库)

我们的三个核心创新

1. 单一 LLM + ReAct 统一框架 Qwen2.5-7B 同时处理搜索生成和动作选择，Thought+Action 提供可追溯推理。416次测试 0 格式错误。
2. Prompt 层消融 + 搜索瓶颈定位 5 种 Prompt 变体系统消融，发现 keyword_only 翻倍成功率。这个发现直接支撑 SFT 训练方向。
3. System A/B/C 递进对比 + Bandit 控制器 零样本(A)→SFT(B)→SFT+Bandit(C) 三层增量，每层可独立归因。Thompson Sampling 在搜索改写/比较/反思/购买四臂间动态权衡。原论文无策略层。


数据范围选择与关键决策

· 初期选 small (1K) ：快速迭代，1天内跑通全管线
· 意外发现 mismatch ：IL轨迹在大库有效、小库归零 → 3个数量级的环境鸿沟
· 当前切换 full (1.18M) ：消除训练/评估分布偏移，对标标准 benchmark
· 递进式保证安全：先低成本的 Prompt 层定位瓶颈，再投入训练。SFT 四次失败反而验证了这个方法论

实验流程全景图

从零样本基线到 System A/B/C 三系统对比的完整链路

八阶段递进式实验路线



P1-P2B 已完成 P2C SFT 失败(环境bug) Fix 进行中(full数据) P2D-P3 待冲刺

数据流向：从原始轨迹到训练样本



各阶段关键产出

阶段	核心产出	关键指标
P1	ReAct baseline 验证	28% SR · 0 无效动作
P2A	500 条自收集轨迹	max_steps=7 最优
P2B	5 种 Prompt 消融	keyword_only +100%
P2C	4 组 LoRA SFT 实验	全低于 baseline (6%)

最终目标：System A/B/C

A · Zero-shot	28% SR (已有)
B · + LoRA SFT	目标 40-50%
C · + Bandit	目标 45-55%

阶段一：基线表现与 Prompt 消融发现

锁定核心瓶颈：搜索词过长引发的级联失败

28%

Zero-shot SR (r>0.5)

0.22

Avg Reward · 0 无效动作

150 条

Baseline (max_steps=7)

300 条

Keyword-only 收集


瓶颈定位：

68% 的失败源于

max_steps 耗尽

。模型倾向于生成 10+ 词的自然语言搜索，导致搜索引擎命中率为 0。max_steps 从 10→7 不降 SR，加速 25%。

Prompt 消融实验 (5 variants × 30 goals)



关键洞察：

注入

"Use SHORT keyword queries"

指令，成功率翻倍。证明：

行为习惯（搜索策略）比模型能力更关键。

阶段二：SFT 尝试与环境错配分析

直面负面结果：1.18M 专家数据无法在 1K 小库生效

SFT版本	数据源	规模	SR	失败原因
v1	自收集 (r>0.5)	134条	20%	数据量少 + 阈值低
v2	IL原始轨迹 (HTML)	1,571条	5%	HTML ≠ Text 观测
v2b	query pair 孤立格式	500对	0%	训练格式 ≠ ReAct推理格式
v3	统一清洗 ReAct chat	14,544条	6%	1.18M 搜索策略 ≠ 1K 搜索策略




数据资产盘点：

- **goal_query_map (1,506对)：**
人工标注的最优搜索词（金矿，待Full环境启用）。•
- **human_goals (12,087条)：**
全量指令集，仅用前600条，留待 Full 环境大规模评估。•
- **自收集 500 条：**
可作为 DPO 负样本 + 失败模式分析。

学术对标与冲刺计划

对标 A3T (2024 SOTA) 确立后续迭代路线

A3T 核心增量拆解 (WebShop Score)



A3T 证明 7B 模型通过 **r=1.0 筛选 + 4轮迭代** 可达 74% Score。我们的 Qwen-7B 基线优于其初始基准。



最终交付：三系统对比矩阵

System A · Zero-shot + Keyword Prompt
28% SR — 零样本冷启动基线，证明 7B 模型内建购物推理能力

System B · System A + LoRA SFT 微调
目标 40-50% SR — r=1.0 筛选 + PG 策略梯度 + 3-4轮自训练

System C ★ · System B + Bandit 策略控制器
目标 45-55% SR — Thompson Sampling 优化搜索/比较/购买时机

P0 今晚死线：
完成 Full 数据集本地索引下载 + 锁定 500 条标准 test split + 补齐 Task Score 与 Strict SR 评估指标。

结项冲刺：从复现到优化

已验证 7B 模型零样本具备购物潜质，

已定位"搜索错配"这一核心环境瓶颈。

下一步将通过 环境对齐、完美数据筛选与 **Bandit** 策略控制，

实现对 WebShop 经典基准的深度优化与突破。

500 条

自收集轨迹

14,544 条

统一清洗数据

~10 个

实验脚本

NLP Final Project · Group 34 · 2026-05-28